

Aplicación de Redes Neuronales Convolucionales (CNN) desde cero para la Identificación de Patologías Pulmonares en Radiografías de Tórax

Nataly Lanchimba / Dario Herrera / Jordy Cevallos

Universidad Internacional del Ecuador

Profesor: Jefferson Rodriguez | Semana 2

Código fuente

Proyecto en GitHub / Jupyter Notebook [UIDE_G2_W2_MCDA_A_NOV25_Notebook.ipynb](#)

1. Resumen del Problema

El presente proyecto constituye la continuación del trabajo de la Semana 1, en el que se utilizó un Perceptrón Multicapa (MLP) sobre el dataset *ChestX6: Multi-Class X-ray Dataset*. En esta segunda entrega se implementa una **Red Neuronal Convolutiva (CNN) desde cero**— sin pesos pre-entrenados— para el mismo problema de clasificación automática de radiografías de tórax en seis categorías de condiciones pulmonares/torácicas.

La motivación principal del cambio de arquitectura es que las imágenes de rayos-X son datos espaciales 2D donde los patrones locales (nódulos, infiltrados, cardiomegalia) son naturalmente detectables mediante filtros convolucionales. Las CNN son la solución óptima por cuatro razones:

- **Invarianza traslacional:** los filtros detectan patrones en cualquier zona de la imagen.
- **Jerarquía de características:** capas tempranas capturan bordes y texturas; capas profundas capturan estructuras anatómicas complejas.
- **Eficiencia paramétrica:** el peso compartido reduce drásticamente los parámetros frente a una red densa.
- **Evidencia empírica:** las CNN dominan los benchmarks de imagen médica (CheXNet, etc.).

Una RNN no sería adecuada (datos no secuenciales) ni un Transformer puro (requeriría muchos más datos para converger desde cero).

2. Preparación del Dataset

2.1. Descripción del Dataset


Se emplea el mismo *ChestX6* de la Semana 1: 18 036 imágenes de radiografías de tórax en escala de grises, distribuidas en seis clases de condiciones pulmonares: *Normal*, *Pneumonia-Bacterial*, *Pneumonia-Viral*, *COVID-19*, *Tuberculosis* y *Emphysema*.

El dataset es relativamente equilibrado. La clase con más imágenes es *Normal* (3 271) y la con menos es *Emphysema* (2 550), una diferencia de apenas el 28 % entre extremos, de modo que el desbalance no es severo. La división predefinida respeta una proporción aproximada de 80/10/10, eliminando el riesgo de *data leakage*. Las características principales del dataset se resumen en el Cuadro 1.

Cuadro 1: Ficha técnica del dataset ChestX6

Característica	Descripción
Número de muestras	18 036 imágenes
Modalidad	Radiografía de tórax
Espacio de color	Escala de grises (1 canal nativo; RGB en CNN)
Resolución nativa	224 × 224 px
Resolución usada (CNN)	128 × 128 px
N.º de clases	6
Partición Train	14 551 imágenes (80.7 %)
Partición Validation	1 748 imágenes (9.7 %)
Partición Test	1 737 imágenes (9.6 %)
Tipo de tarea	Clasificación multiclase

Figura 1: Distribución de imágenes por clase del conjunto de datos



Como se puede ver en la Figura 1 presenta la distribución de imágenes por clase en los conjuntos de entrenamiento, validación y prueba. Se observa una distribución relativamente balanceada entre las diferentes categorías, con ligeras variaciones en el número de muestras disponibles. La clase Normal presenta la mayor cantidad de imágenes, mientras que Emphysema contiene el menor número de observaciones. Mientras que en validación y test se tienen proporciones similares en cada clase.

2.2. Preprocesamiento del Dataset


Se aplicaron las siguientes transformaciones para adaptar las imágenes al formato de entrada de la CNN:

Reescalado: de 224×224 a 128×128 píxeles. Esta reducción equilibra coste computacional y detalle anatómico suficiente para la clasificación.

Normalización: división por 255, mapeando los valores de píxel al rango $[0, 1]$ para estabilizar el gradiente durante el *backpropagation* y acelerar la convergencia del optimizador.

Aumento de datos (solo en entrenamiento): *flip* horizontal, rotación leve ($\pm 5\%$), zoom ($\pm 10\%$), contraste ($\pm 15\%$), brillo ($\pm 15\%$) y traslación ($\pm 10\%$). Estas transformaciones simulan variaciones naturales en la toma de radiografías—diferencias de posicionamiento del paciente o ajustes del equipo—sin distorsionar la información clínica relevante. Como se puede ver a continuación en la 2:

Figura 2: Argumentación de la data



Class weights: se calcularon pesos de clase con `compute_class_weight('balanced')` para compensar el leve desbalance y evitar sesgo hacia las clases mayoritarias.

3. Implementación y Entrenamiento del Modelo

3.1. Arquitectura de la CNN

La arquitectura está inspirada en VGG: bloques *conv* $\times 2$ + *MaxPooling*, sin pesos pre-entrenados. El diseño es progresivo ($32 \rightarrow 64 \rightarrow 128 \rightarrow 256$ filtros) para capturar características de complejidad creciente:

- Bloque 1** (32 filtros): detecta bordes, gradientes y texturas de bajo nivel. $\text{Conv2D}(32) \times 2 + \text{BN} + \text{ReLU} + \text{MaxPool} + \text{Dropout}(0.10)$ $128 \rightarrow 64$ px.
- Bloque 2** (64 filtros): patrones intermedios, contornos anatómicos. $\text{Conv2D}(64) \times 2 + \text{BN} + \text{ReLU} + \text{MaxPool} + \text{Dropout}(0.15)$ $64 \rightarrow 32$ px.
- Bloque 3** (128 filtros): estructuras complejas, silueta cardíaca, nódulos, infiltrados. $\text{Conv2D}(128) \times 2 + \text{BN} + \text{ReLU} + \text{MaxPool} + \text{Dropout}(0.20)$ $32 \rightarrow 16$ px.
- Bloque 4** (256 filtros): representaciones de alto nivel específicas de cada clase. $\text{Conv2D}(256) \times 2 + \text{BN} + \text{ReLU} + \text{MaxPool} + \text{Dropout}(0.25)$ $16 \rightarrow 8$ px.
- Cabecera:** $\text{GlobalAveragePooling2D} + \text{Dense}(512) + \text{BN} + \text{ReLU} + \text{Dropout}(0.30) + \text{Dense}(256) + \text{BN} + \text{ReLU} + \text{Dropout}(0.35) + \text{Dense}(6, \text{Softmax})$.

El *Global Average Pooling* sustituye a *Flatten* para mejorar la generalización con menos parámetros. La regularización L_2 ($\lambda = 10^{-4}$) se aplica en las capas densas. El Cuadro 2 resume la configuración completa.

Cuadro 2: Configuración de la arquitectura CNN

Bloque	Neuronas	Regularización	Salida
Conv Bloque 1	32×2	BN + Dropout(0.10)	64^2
Conv Bloque 2	64×2	BN + Dropout(0.15)	32^2
Conv Bloque 3	128×2	BN + Dropout(0.20)	16^2
Conv Bloque 4	256×2	BN + Dropout(0.25)	8^2
GAP	—	—	256
Dense 1	512	BN+L2+Dropout(0.30)	512
Dense 2	256	BN+L2+Dropout(0.35)	256
Salida	6	Softmax	6

Función de pérdida	Sparse Cat. Crossentropy
Optimizador	Adam + Cosine Decay
LR inicial	5×10^{-4}
Épocas máx.	20
Batch size	32

3.2. Entrenamiento

Se utilizó un *scheduler* de tasa de aprendizaje **Cosine Decay** (decaimiento desde 5×10^{-4} hasta 10^{-5}) en lugar del `ReduceLRonPlateau` empleado en la Semana 1, lo que produce una reducción suave y continua que evita oscilaciones tardías. Los *callbacks* configurados fueron:

- **EarlyStopping** (paciencia=10, restaura mejores pesos, $\Delta_{\min} = 10^{-4}$).
- **ModelCheckpoint** — guarda el mejor modelo según `val_accuracy`.
- **CSVLogger** — registro del historial de entrenamiento.

Los pesos de clase fueron calculados con el objetivo de reducir el efecto del desbalance entre categorías durante el proceso de entrenamiento. Se observa que la clase *Emphysema* presenta el peso más alto (1.183), indicando una menor representación relativa dentro del conjunto de entrenamiento, mientras que la clase *Normal* presenta el menor peso (0.908), debido a su mayor número de muestras disponibles. Esta estrategia permite penalizar más los errores en clases menos representadas y contribuir a un aprendizaje más equilibrado del modelo.

Cuadro 3: Pesos de clase calculados para el entrenamiento del modelo

Clase	Peso
Covid-19	1.003
Emphysema	1.183
Normal	0.908
Pneumonia-Bacterial	1.010
Pneumonia-Viral	1.005
Tuberculosis	0.933

4. Análisis del Preprocesamiento

4.1. Efecto del Data Augmentation

Las transformaciones aplicadas al conjunto de entrenamiento (*flip* horizontal, rotación leve, zoom, contraste y brillo) producen imágenes visualmente diferentes pero clínicamente equivalentes: siguen siendo radiografías válidas que un médico diagnosticaría de la misma manera. Este comportamiento es el deseado: aumentar artificialmente

la diversidad de entrenamiento sin introducir distorsiones que alteren el diagnóstico.

4.2. Diferencias morfológicas entre clases

Entre las seis clases se observan diferencias morfológicas importantes: *Tuberculosis* presenta cavitaciones en lóbulos superiores y fibrosis; *COVID-19* y *Emphysema* comparten opacidades bilaterales difusas; *Pneumonia-Bacterial* y *Pneumonia-Viral* presentan infiltrados intersticiales bilaterales similares, lo que constituye el principal desafío de clasificación del modelo.

5. Evaluación del Modelo

El rendimiento del modelo se evaluó sobre el conjunto de prueba utilizando *accuracy*, precisión, *recall* y *F1-score*, junto con la matriz de confusión y el análisis de métricas por clase. Adicionalmente se reporta la *Top-2 Accuracy* como métrica complementaria.

5.1. Métricas globales

Las curvas de entrenamiento y validación muestran convergencia estable. El análisis del *gap* train-val confirma un ligero sobreajuste (*gap* 2–10 %), aceptable para CNNs entrenadas desde cero. El resumen de métricas sobre el conjunto de test se presenta en el Cuadro 4.

Cuadro 4: Métricas de evaluación en el conjunto de test

Métrica	Valor
Test Loss	(0.4259)
Test Accuracy	(0.8549)
Top-2 Accuracy	(0.9879)
Precision (weighted)	(0.8553)
Recall (weighted)	(0.8549)
F1-Score (weighted)	(0.8537)

El análisis de las métricas globales presentado en la Tabla 4 evidencia un desempeño satisfactorio del modelo en el conjunto de prueba. La exactitud alcanzó un valor de 0.8549, indicando que aproximadamente el 85.49 % de las imágenes fueron clasificadas correctamente. Asimismo, el modelo obtuvo un F1-score ponderado de 0.8537, mostrando un adecuado equilibrio entre precisión y sensibilidad. La precisión ponderada (0.8553) y el *recall* ponderado (0.8549) presentan valores similares, sugiriendo un comportamiento estable entre las diferentes categorías. Adicionalmente, la métrica *Top-2 Accuracy* alcanzó un valor de 0.9879, lo que indica que en el 98.79 % de los casos la clase correcta se encuentra entre las dos predicciones con mayor probabilidad.

Cuadro 5: Métricas de desempeño del modelo por clase

Clase	Precision	Recall	F1-score
Covid-19	0.8870	0.8633	0.8750
Emphysema	0.8566	0.8840	0.8701
Normal	0.9241	0.9733	0.9481
Pneumonia-Bacterial	0.7717	0.6533	0.7076
Pneumonia-Viral	0.6988	0.7733	0.7342
Tuberculosis	1.0000	0.9930	0.9965

5.2. Análisis por clase


Las métricas por clase permiten identificar las clases con mayor dificultad de clasificación. De manera consistente con los resultados de la Semana 1, se espera que:

- **Tuberculosis** obtenga el F1-score más alto, dado que sus patrones radiológicos (cavitaciones en lóbulos superiores, fibrosis) son morfológicamente únicos.
- **Pneumonia-Viral** y **Pneumonia-Bacterial** registren el peor desempeño relativo, debido al solapamiento visual de infiltrados intersticiales bilaterales difusos.

5.3. Matriz de confusión

Las matrices de confusión (absoluta y normalizada) permiten identificar los patrones de error del modelo. Como se puede ver en la siguiente gráfica:

Figura 3: Matriz de confusión



Las principales confusiones esperadas se concentran entre:

- **Pneumonia-Bacterial** ↔ **Pneumonia-Viral**: solapamiento visual de infiltrados intersticiales.
- **COVID-19** ↔ **Emphysema**: ambas presentan opacidades bilaterales difusas.

5.4. Desempeño en entrenamiento y validación

La curva de entrenamiento (azul) baja de forma suave y continua durante las 20 épocas, lo cual indica que el modelo aprendió de manera progresiva y estable. La curva de validación (rojo) es más irregular, con picos notables alrededor de las épocas 5–6 y 11, pero la tendencia general también es descendente. Que ambas converjan hacia valores similares ($\sim 0,5$) al final es una buena señal: el modelo no está memorizando los datos de entrenamiento.




Figura 4: Curvas de desempeño

La curva de entrenamiento sube de forma constante hasta alcanzar 0.9154 al final. La de validación es más inestable al inicio (lo cual es normal con augmentation fuerte), pero se estabiliza a partir de la época 12 aproximadamente, terminando en 0.8358. El mejor epoch identificado fue el 18, con la mejor combinación entre el error del modelo y la exactitud de validación.

5.5. Predicciones del modelo

El análisis visual de las predicciones correctas e incorrectas evidencia que el modelo identifica adecuadamente patologías con patrones radiológicos distintivos, como tuberculosis y enfisema. Sin embargo, presenta dificultades para diferenciar enfermedades con características similares, particularmente entre neumonía viral y bacteriana. Además, se observaron casos críticos donde imágenes patológicas fueron clasificadas como normales con alta confianza, lo cual sugiere posibles problemas de generalización o desbalance entre clases y resalta la necesidad de mejorar el proceso de entrenamiento.




Figura 5: Predicciones

tades en las clases de neumonía. La confusión entre *Pneumonia-Bacterial* y *Pneumonia-Viral* es médicamente esperada: ambas condiciones comparten infiltrados intersticiales bilaterales difusos, diferenciables principalmente por marcadores clínicos y de laboratorio más que por apariencia radiológica. Como pasos futuros se recomienda implementar *transfer learning* con DenseNet-121 o EfficientNetB3, aplicar *focal loss* para penalizar más los errores en estas clases difíciles, y explorar técnicas de aumento de datos específicas que exageren las diferencias entre patrones bacterianos y virales.

5. **Proyección hacia la Semana 3 (Transfer Learning):** los modelos candidatos son DenseNet-121 (conexiones densas que capturan gradientes finos de estructuras pulmonares), EfficientNetB3 (alto ratio *accuracy*/parámetros gracias al *compound scaling*) y ResNet-50 (*baseline* robusto con *skip connections* que evitan el *vanishing gradient*). La estrategia consistirá en *fine-tuning* con pesos *imagenet* descongelando los últimos bloques y añadiendo una nueva cabecera para 6 clases.

Referencias

- [1] TensorFlow Documentation (2024). <https://www.tensorflow.org/>
- [2] Mohamed Asak (2024). *ChestX6: Multi-Class X-ray Dataset*. Kaggle. kaggle.com/datasets/mohamedasak/chest-x-ray-6-classes
- [3] Rajpurkar et al. (2017). CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays. *arXiv:1711.05225*.
- [4] Scikit-learn developers (2024). Neural network models (supervised). scikit-learn.org

6. Conclusiones

1. **La CNN supera al MLP aprovechando la estructura espacial de las imágenes.** Mientras el MLP de la Semana 1 trataba cada imagen como un vector plano de 4096 valores perdiendo toda la información espacial (logrando un 86.13 % de *accuracy*), la CNN extrae jerarquías de características locales mediante filtros convolucionales, lo que se traduce en una mejora directa sobre clases con patrones morfológicos complejos.
2. **El diseño progresivo de filtros (32 → 256) y el Global Average Pooling son fundamentales.** La arquitectura VGG-like permite capturar desde bordes y texturas hasta estructuras anatómicas complejas de manera jerárquica. El *GlobalAveragePooling2D* mejora la generalización frente al *Flatten* clásico, reduciendo significativamente el número de parámetros en la cabecera clasificadora.
3. **El Cosine Decay produce convergencia más suave que el ReduceLROnPlateau.** Al decaer la tasa de aprendizaje de forma continua y predecible, se evitan los saltos abruptos que pueden desestabilizar el entrenamiento en épocas tardías. Esto contribuye a curvas de entrenamiento más estables.
4. **El model generaliza bien pero persisten dificultades**